

Système Intelligent Multi-Modèles

pour la Maintenance Prédictive Industrielle

Projet M2 Data Science — EFREI 2025-26

Khalil DJAHEL / Bryan BONTRAIN

RNCP36739 — Bloc 4

Contexte et problème

Maintenance corrective	Maintenance prédictive
Panne survenue → réparation d'urgence	Signal capteur dégradé → intervention planifiée
Arrêt non planifié, coûts élevés	Coût maîtrisé, zéro surprise
Risque opérateur	Sécurité préservée

Notre approche

Classification binaire supervisée sur la variable `failure_within_24h`.

Les capteurs industriels (vibration, température, pression, RPM) génèrent en continu des signaux porteurs de patterns annonciateurs de panne. L'objectif est de les exploiter pour détecter une défaillance 24 heures à l'avance.

Dataset et pipeline

24 042 observations — 9 features retenues — 4 types de machines

Trois colonnes supprimées pour éviter le **data leakage** :

Colonne supprimée	Raison
<code>failure_type</code>	Révèle directement qu'une panne est en cours
<code>rul_hours</code>	Encode implicitement la cible (corrélation -0.25)
<code>estimated_repair_cost</code>	Calculé après la panne, indisponible en temps réel

Pipeline sklearn (anti-leakage)

```
Split stratifié 80/20 → ColumnTransformer ajusté sur TRAIN uniquement  
Numériques (7) : Median Imputer + StandardScaler  
Catégorielles (2): Mode Imputer + OneHotEncoder
```

Toutes les statistiques de preprocessing sont calculées sur le train set, puis appliquées sur le test set sans contamination.

Les 4 modèles


Modèle	Principe	Gestion du déséquilibre (85/15)
Logistic Regression	Combinaison linéaire + sigmoïde — baseline	<code>class_weight='balanced'</code>
Random Forest	200 arbres indépendants, vote (bagging)	<code>class_weight='balanced'</code>
XGBoost	200 arbres séquentiels, chacun corrige le précédent (boosting)	<code>scale_pos_weight=5.75</code>
MLP Deep Learning	128 → 64 → 32 neurones, ReLU, backpropagation	<code>early_stopping=True</code>

Métriques retenues


Le Recall est prioritaire : un faux négatif (panne non détectée) est le cas le plus coûteux industriellement. Le F1-Score équilibre Recall et Precision. L'Accuracy seule est trompeuse sur un dataset déséquilibré.

Résultats

Modèle	Recall	F1-Score	ROC-AUC
Logistic Regression	0.895	0.747	0.959
Random Forest	0.916	0.887	0.993
XGBoost	0.955	0.898	0.996
MLP Deep Learning	0.853	0.850	0.984



Interprétabilité



Dashboard et conclusion

Dashboard Streamlit — 4 onglets : EDA, comparaison des modèles, prédiction en temps réel, interprétabilité.

```
streamlit run dashboard/app.py
```

Bilan

XGBoost retenu : $F1 = 0.898$ — $\text{Recall} = 0.955$ — $\text{ROC-AUC} = 0.996$

Avec un Recall de 95.5 %, le système détecte 19 pannes sur 20 avant leur survenue, permettant de planifier des interventions préventives à moindre coût.

Perspectives : features temporelles (rolling mean 1 h / 6 h), ajustement du seuil de décision, monitoring de dérive, API REST FastAPI.