

Système Intelligent Multi-Modèles

pour la Maintenance Prédictive Industrielle

Soutenance — M2 Data Engineering et IA — EFREI 2025-26

Khalil DJAHEL / Bryan BONTRAIN

RNCP36739 — Bloc 4 — Formatrice : Sarah MALAEB

Contexte et problème métier

Maintenance corrective	Maintenance prédictive
Panne survenue → réparation d'urgence	Signal capteur dégradé → intervention planifiée
Arrêt non planifié, coûts élevés	Coût maîtrisé, zéro surprise
Risque opérateur	Sécurité préservée

"Un système intelligent multi-modèles permettant de détecter une panne industrielle 24 heures à l'avance, pour aider les responsables maintenance à planifier des interventions préventives à moindre coût."

Tâche : Classification binaire supervisée — variable cible : `failure_within_24h`

Analyse du besoin utilisateur

Utilisateur cible : responsable maintenance / ingénieur opérationnel (profil non technique)

Scénario d'usage	Besoin	Réponse de la solution
Surveillance quotidienne	Quelles machines surveiller en priorité ?	Score de risque coloré par machine
Alerte imminente	Cette machine doit-elle être arrêtée ?	Probabilité + recommandation 24h
Bilan de performance	Peut-on faire confiance au système ?	Tableau comparatif des modèles

Contraintes : interface non technique · résultat lisible en 5 secondes · prédiction en temps réel

Valeur ajoutée : détecter 19 pannes sur 20 avant leur survenue → réduire les arrêts non planifiés et leurs coûts d'urgence

Méthodologie et organisation du projet

Approche Agile / Kanban — sprints hebdomadaires, revue des livrables en binôme

Sprint	Contenu	Outils
1	Compréhension du sujet, EDA	Jupyter, Pandas, Matplotlib
2	Preprocessing, pipeline anti-leakage	sklearn, ColumnTransformer
3	Modélisation (4 algorithmes ML/DL)	XGBoost, sklearn, Keras/MLP
4	Évaluation, SHAP, interprétabilité	SHAP, Matplotlib, cross-validation
5	Dashboard Streamlit, soutenance	Streamlit, Marp

Répartition : Khalil (pipeline, modèles ML/DL, SHAP) · Bryan (EDA, dashboard, rapport)

Risques gérés : déséquilibre 85/15 · data leakage · overfitting MLP · performance Deep Learning limitée


Référentiel de données

Source : Kaggle — Industrial Machine Predictive Maintenance Dataset


Attribut	Valeur
Observations	24 042
Variables retenues	9 features + 1 cible
Types de machines	CNC, Pump, Compressor, Robotic Arm
Variable cible	failure_within_24h (0/1)
Déséquilibre	85.2 % pas de panne · 14.8 % panne imminente

Features capteurs : vibration_rms · temperature_motor · current_phase_avg · pressure_level · rpm · hours_since_maintenance · ambient_temp · machine_type · operating_mode

3 colonnes supprimées (data leakage) : failure_type · rul_hours · estimated_repair_cost



EDA — Exploration et visualisation



Les machines en **pré-panne** (orange) présentent des valeurs systématiquement plus élevées pour `vibration_rms`, `temperature_motor` et `hours_since_maintenance` — cohérent avec la physique industrielle (usure, surchauffe, absence de maintenance).

Pipeline Data Science anti-leakage

```
Données brutes (24 042 lignes · 15 colonnes)
↓ Suppression leakage + identifiants
↓ Split stratifié 80/20 → Train: 19 233 | Test: 4 809
↓
ColumnTransformer [ajusté sur TRAIN uniquement]
  ├── Numériques (7) : Median Imputer → StandardScaler
  └── Catégorielles (2) : Mode Imputer → OneHotEncoder
↓
Entraînement → 4 modèles (LR · RF · XGBoost · MLP)
↓
Évaluation comparative (Recall · F1 · ROC-AUC)
↓
Modèle retenu : XGBoost → SHAP → Dashboard Streamlit
```

Toutes les statistiques de preprocessing calculées **uniquement sur le train set**, jamais sur le test.


Les 4 modèles

Modèle	Principe	Gestion déséquilibre (85/15)
Logistic Regression	Combinaison linéaire + sigmoïde — baseline	<code>class_weight='balanced'</code>
Random Forest	200 arbres indépendants, vote (bagging)	<code>class_weight='balanced'</code>
XGBoost	200 arbres séquentiels, correction progressive (boosting)	<code>scale_pos_weight=5.75</code>
MLP Deep Learning	128 → 64 → 32 neurones, ReLU, backpropagation	<code>early_stopping=True</code>

Métriques prioritaires : Recall (FN = panne ratée → cas le plus coûteux industriellement) · F1-Score · ROC-AUC


Résultats comparatifs

Modèle	Recall	F1-Score	ROC-AUC
Logistic Regression	0.895	0.747	0.959
Random Forest	0.916	0.887	0.993
XGBoost ✓	0.955	0.898	0.996
MLP Deep Learning	0.853	0.850	0.984



Cross-validation 5-fold XGBoost : **F1 = 0.9026 ± 0.0099** — stable, pas d'overfitting

Interprétabilité — SHAP



Top 5 : `vibration_rms` · `temperature_motor` · `hours_since_maintenance` · `rpm` · `pressure_level`

Rouge = valeur élevée → augmente le risque de panne · Bleu = valeur faible → réduit le risque

Dashboard décisionnel

Streamlit — 4 onglets orientés utilisateur métier

Onglet	Valeur métier
EDA	Visualisation des signaux capteurs et corrélations
Modèles	Tableau comparatif, courbes ROC, matrices de confusion
Prédiction	Score de risque coloré + recommandation en temps réel
Interprétabilité	Feature importance + SHAP pour chaque alerte

Cas d'usage : saisir les valeurs capteurs d'une machine → obtenir un score de risque (**ÉLEVÉ / FAIBLE**) avec probabilité et recommandation d'intervention dans les 24h

```
streamlit run dashboard/app.py → http://localhost:8501
```

Limites et pistes d'amélioration

Limites actuelles

- **Dataset simulé** → performances probablement inférieures sur données industrielles réelles (bruit capteurs, variabilité inter-machines)
- **Absence de features temporelles** → chaque mesure est traitée indépendamment (pas de tendance d'évolution)
- **Seuil de décision fixe à 0.5** → devrait être ajusté selon le ratio coût panne / coût intervention
- **MLP limité** → Deep Learning efficace à partir de 100k+ observations ou séries temporelles longues

Pistes d'amélioration

- Rolling features (moyenne glissante 1h / 6h) pour capturer les tendances de dégradation
- Ajustement du seuil de décision selon le coût métier réel
- Monitoring de dérive des capteurs (data drift) en production
- Réentraînement périodique + déploiement cloud
- API REST FastAPI pour intégration SCADA/ERP (optionnel)

Conclusion

Ce que nous avons réalisé

Pipeline Data Science complet : EDA → preprocessing anti-leakage → 4 modèles → évaluation comparative → interprétabilité SHAP → dashboard décisionnel

Modèle retenu — XGBoost

Métrique	Valeur	Signification métier
Recall	0.955	19 pannes sur 20 détectées avant survenue
F1-Score	0.898	Équilibre précision / détection
ROC-AUC	0.996	Quasi-parfaite discrimination des classes

Compétences acquises : EDA · Preprocessing · ML supervisé · Deep Learning · Évaluation rigoureuse · Interprétabilité (SHAP) · Dashboard Streamlit · Gestion de projet Agile

Passage d'un dataset brut à un outil décisionnel opérationnel, explicable et défendable dans un contexte professionnel.